

ПРИМЕНЕНИЕ НЕЙРОННЫХ СЕТЕЙ ДЛЯ ЗАДАЧ ДИАГНОСТИКИ ГЦН ПО ДАННЫМ ОПЕРАТИВНОГО ТЕХНОЛОГИЧЕСКОГО КОНТРОЛЯ

С.Т. Лескин, В.В. Валуй, Д.Г. Зарюгин

Обнинский институт атомной энергетики, г. Обнинск



Обсуждаются вопросы создания нейронной сети для диагностики состояния главных циркуляционных насосов АЭС с ВВЭР-1000. На основании выбранной модели и принципа обучения разработана нейронная сеть. Представлены результаты работы нейронной сети, предварительно обученной на данных пятого блока НВ АЭС и первого блока Калининской АЭС. Проведен анализ чувствительности нейронной сети по входным параметрам для выделения из них наиболее влияющих на процесс обучения распознаванию аномального состояния ГЦН.

ВВЕДЕНИЕ

После ряда аварий, произошедших на атомных станциях, стали неуклонно возрастать требования к надежности элементов технологических систем ядерных установок. В настоящее время глобальной проблемой эксплуатации оборудования в энергосистемах является поддержание его работоспособности экономическими мерами. Расчеты показывают, что оптимальное проведение профилактических мероприятий в соответствии с текущим состоянием объектов снижает до пяти раз расходы на ремонты и ущербы от перерывов энергоснабжения. Например, недовыработка электроэнергии за первое полугодие 2000 г. из-за нарушений в работе энергоблоков и отказов оборудования составила 1545,3 млн. кВт*ч [1]. Отказы насосного оборудования на АЭС с ВВЭР составляют около 6% от общего числа нарушений [2] и эта цифра практически не уменьшается.

Таким образом, одной из задач обеспечения надежной работы АЭС является создание сравнительно недорогой системы оперативной диагностики ГЦН, которая могла бы своевременно обнаружить и идентифицировать аномальные процессы в элементах оборудования ГЦН до развития нарушений, связанных с отключениями насоса.

Для решения задач диагностирования сложных систем, к которым следует отнести ГЦН, когда множество параметров, определяющих состояние объекта, имеет большую размерность, а физическая природа процессов, происходящих с насосом, трудно формализуема, наиболее эффективно использование математического аппарата теории распознавания образов и кластерного анализа. В классической постановке задачи распознавания предполагается, что на этапе моделирования имеется априорная информация о нормальном и аномальном режимах работы оборудования [3,4]. Если авария данного типа устойчиво проявляется в некотором наборе измеряемых параметров, то, исполь-

зуя методологию нейронных сетей [5], можно построить систему, эффективно распознающую такую ситуацию в дальнейшем. Для обучения нейронной сети распознаванию аварийной ситуации на ранней стадии ее развития необходима надежная информация о факте ее возникновения. Как показала практика, до самого процесса аварийного отключения насоса его параметры находятся в эксплуатационных пределах, и в рамках традиционного подхода (контроля за отклонениями параметров) нет оснований считать его аномальным. Использование программного комплекса диагностики ГЦН ДИНА-1 для анализа данных оперативного контроля на реальных данных Калининской и Нововоронежской АЭС показало [6], что аномалия в состоянии ГЦН проявляется задолго до обнаружения нарушения штатными системами контроля. Полученные результаты позволили сформировать образ аномалии, который использовался для конструирования нейронной сети, распознающей раннюю стадию развития аварии ГЦН.

В статье описывается структура нейронной сети, алгоритм обучения распознаванию. Приводятся результаты обработки реальных данных АЭС.

СТРУКТУРА НЕЙРОННОЙ СЕТИ

Система реализована на основе нейронной сети с обратным распространением ошибок (backpropagation) [7]. Структура нейронной сети выбиралась экспериментально исходя из специфики поставленной задачи и выполнения условий сходимости решения. Число входных нейронов равно числу обрабатываемых параметров – в нашем случае семи. Далее следует пять промежуточных слоев. Выходной слой состоит из двух дублирующих друг друга нейронов, с которых снимается выходной сигнал. Сигнал, снимаемый с первого выходного нейрона, отражает состояние насосного агрегата. Второй нейрон дублирует выходной сигнал, что придает процессу обучения устойчивость и позволяет избежать попадания в локальный минимум целевой функции. Нейроны каждого слоя соединены синапсами со всеми нейронами предыдущего и последующего слоев (на рис. 1 показаны связи только для крайних нейронов). Через синапсы нейроны посылают сигналы. Это происходит следующим образом.

В текущий момент времени нейрон передает свой текущий сигнал на все выходящие из него синапсы; одновременно он получает сигналы со всех входящих в него синапсов, а для нейронов входного слоя – внешний входной сигнал.

Полученные сигналы умножаются на веса соответствующих синапсов, суммируются и преобразуются согласно сигмоидной активационной функции

$$y = \sum_i W_i y_i / \left(\alpha + a \operatorname{bs} \left(\sum_i W_i y_i \right) \right),$$

где W_i – значение веса синапса i -го нейрона, y_i – значение выхода i -го нейрона, α – пороговый элемент. Данная функция имеет производную на всей оси абсцисс, что является необходимым условием для сетей “backpropagation”. Кроме того, выбранная функция активации наиболее устойчива при обучении нейронной сети на заданной дисперсии исходных данных.

Результат этой операции берется в качестве входного сигнала для нейронов следующего слоя.

На вход нейронной сети подается вектор, компонентами которого являются значения параметров оперативного контроля ГЦН, нормированные на свой диапазон возможных значений. Выходом сети являются сигналы, снимаемые с двух выходных нейронов, определяющих принадлежность входного вектора к тому или иному классу (аварийный или неаварийный). Если состояние насоса аномально, первый нейрон выдает положительный сигнал; если насос работает нормально, выходной сигнал первого нейрона отрицательный.




Рис.1. Топология нейронной сети

ОБУЧЕНИЕ НЕЙРОННОЙ СЕТИ

Обучение производится путем минимизации целевой функции методом градиентного спуска [8]. Согласно методу наименьших квадратов, минимизируемой целевой функцией ошибки решения обучающего примера нейронной сети является величина

$$E(w) = \frac{1}{2} \sum_j (y_j^{(N)} - d_j)^2, \quad (1)$$

где $y_j^{(N)}$ – реальное выходное состояние нейрона j выходного слоя N нейронной сети, d_j – идеальное (желаемое) выходное состояние этого нейрона.

Суммирование ведется по всем нейронам выходного слоя. Минимизация производится методом градиентного спуска, что означает подстройку весовых коэффициентов следующим образом:

$$\Delta w_{ij}^{(n)} = -\eta \cdot \frac{\partial E}{\partial w_{ij}^{(n)}}. \quad (2)$$

Здесь $w_{ij}^{(n)}$ – весовой коэффициент синаптической связи, соединяющей i -ый нейрон слоя $n-1$ с j -ым нейроном слоя n , η – коэффициент скорости обучения, $0 < \eta < 1$.

Путем несложных математических преобразований получаем формулу для подстройки весов синапсов, соединяющих $n-1$ -ый слой с n -ым слоем:

$$\Delta w_{ij}^{(n)} = -\eta \cdot \delta_j^{(n)} \cdot y_i^{(n-1)}, \quad (3)$$

где $y_i^{(n-1)}$ – сигнал, снимаемый с i -го нейрона слоя $n-1$;

$$\delta_j^{(n)} = \left[\sum_k \delta_k^{(n+1)} \cdot w_{jk}^{(n+1)} \right] \cdot \frac{dy_j}{ds_j}, \quad (4)$$

суммирование ведется по всем нейронам слоя $n+1$.

$$\text{Для выходного слоя} \quad \delta_l^{(N)} = (y_l^{(N)} - d_l) \cdot \frac{dy_l}{ds_l}. \quad (5)$$

Здесь s_j – взвешенная сумма входных сигналов i -го нейрона, то есть аргумент активационной функции. Аналогично для подстройки характеристических параметров α получается соотношение

$$\Delta\alpha_j^{(n)} = -\eta \cdot \zeta_j^{(n)}, \quad (6)$$

где

$$\zeta_j^{(n)} = \left[\sum_k \zeta_k^{(n+1)} \cdot w_{jk}^{(n+1)} \right] \cdot \frac{\partial y_j}{\partial \alpha_j}; \quad (7)$$

для выходного слоя

$$\zeta_l^{(N)} = (y_l^{(N)} - d_l) \cdot \frac{dy_l}{d\alpha_l}. \quad (8)$$

Таким образом, полный алгоритм обучения нейронной сети с помощью процедуры обратного распространения строится следующим образом.

1. Подать на входы сети один из возможных образов (обучающий пример) и в режиме обычного функционирования нейронной сети, когда сигналы распространяются от входов к выходам, рассчитать значения последних. Напомним, что

$$s_j^{(n)} = \sum_{i=0}^M y_i^{(n-1)} \cdot w_{ij}^{(n)}, \quad (9)$$

где M – число нейронов в слое $n-1$; $y_i^{(n-1)} = x_{ij}^{(n)}$ – i -ый вход нейрона j слоя n ;

$$y_j^{(n)} = f(s_j^{(n)}), \text{ где } f() \text{ – сигмоид;} \quad (10)$$

$$y_q^{(0)} = I_{q}, \quad (11)$$

где I_q – q -ая компонента вектора входного образа.

2. Рассчитать $\delta^{(N)}$ и $\zeta^{(N)}$ для выходного слоя по формулам (5) и (8). Рассчитать по формуле (3) и (6) изменения весов $\Delta w^{(N)}$ и изменения характеристических параметров $\Delta\alpha^{(N)}$ слоя N .

3. Рассчитать по формулам (4) и (3), а также (7) и (6) соответственно $\delta^{(n)}$ и $\Delta w^{(n)}$ и $\zeta^{(n)}$ и $\Delta\alpha^{(n)}$ для всех остальных слоев, $n=N-1, \dots, 1$.

4. Скорректировать все веса в нейронной сети

$$w_{ij}^{(n)}(t) = w_{ij}^{(n)}(t-1) + h \cdot \Delta w_{ij}^{(n)}(t) \quad (12)$$

и все характеристические параметры в нейронной сети

$$\alpha_j^{(n)}(t) = \alpha_j^{(n)}(t-1) + h \cdot \Delta\alpha_j^{(n)}(t), \quad (13)$$

где h – шаг обучения.

5. Если ошибка сети существенна, перейти на шаг 1. В противном случае – конец.

Параллельно процессу обучения проводится анализ чувствительности нейронной сети к компонентам входного вектора. За показатель чувствительности принимается производная функции оценки по i -ому входу:

$$x_i^{(1)} = \sum_{j=1}^{N^{(2)}} \delta_j^{(2)} \cdot w_{ij}^{(2)}, \quad (14)$$

где $i = 1..N^{(1)}$, $N^{(1)}$ и $N^{(2)}$ – соответственно число нейронов в первом и втором слоях.

Экспериментально получено, что система требует не менее 10000 циклов обучения, что является приемлемым значением для данного класса сетей. На каждом шаге проводится коррекция весовой матрицы сети и характеристических параметров нейронов согласно описанному выше алгоритму. Обучение считается завершенным, когда сеть распознает все примеры обучающей выборки с заданной точностью. Длительность обучения зависит от используемой вычислительной техники.

ОБРАБОТКА ДАННЫХ КАЛИНИНСКОЙ И НОВОВОРОНЕЖСКОЙ АЭС

Обучение нейронной сети проводилось на данных, соответствующих периоду повышенной вибрации ГЦН-2 блока 1 Калининской АЭС и на данных, предшествующих аварии ГЦН-1 блока 5 Нововоронежской АЭС. С помощью программного комплекса диагностики ГЦН DINA-1 было выделено развитие аномального состояния насосов [6]. На основании данных работы комплекса был сформирован набор обучающих примеров.

Для обучения использовались семь параметров оперативного технологического контроля, представленных в табл. 1. Обучающая выборка составлена на 55 примерах, соответствующих нормальному и аномальным состояниям ГЦН.

Таблица 1

№ пар.	Наименование параметра
1	Перепад давления на ГЦН
2	Расход запирающей воды на входе
3	Расход запирающей воды на сливе
4	Давление за первой ступенью
5	Давление запирающей воды на выходе из ГЦН
6	Температура запирающей воды на сливе
7	Температура масла на входе

Результаты обработки данных Нововоронежской АЭС представлены на рис. 2. Как видно из рисунка, сеть явным образом различает аномальную ситуацию на ГЦН-1. Сначала идет период нормальной работы насоса, потом период нестабильного состояния и, наконец, период резкого возрастания аномалии, заканчивающейся аварией насоса. При обработке данных по другим одновременно работающим насосам сеть не обнаружила аномального состояния. На рис. 3 представлены результаты обработки данных Калининской АЭС. Сеть четко распознает аномальное состояние

ГЦН-2 на протяжении всего рассматриваемого периода повышенной вибрации. На остальных насосах аномалия отсутствует.

Оценка эффективности распознавания аномалии с помощью разработанной нейронной сети показала, что вероятность ошибки распознавания аномалии (ошибка 1-го рода)




Рис.2. Результаты обработки данных Нововоронежской АЭС




Рис.3. Результаты обработки данных Калининской АЭС

приблизительно равна 4%, а вероятность ошибки принятия решения о наличии аномалии когда ГЦН в нормальном состоянии (ошибка 2-го рода) равна 0.8%.

Показатели чувствительности параметров к распознаванию аномалии ГЦН графически представлены на рис.6., здесь номера параметров соответствуют табл. 1.

Из рис. 4 видно, что наиболее информативными для процесса обучения сети являются давление за первой ступенью и давление запирающей воды на выходе. Таким образом, можно сделать вывод, что аномальное состояние данных насосов проявляется в параметрах, относящихся к блоку уплотнений. Действительно, ревизия выемной части ГЦН-2 Калининской АЭС в период планового предупредительного ремонта и ГЦН1 Нововоронежской АЭС после аварии показала необходимость ремонта блока уплотнений. Полученные результаты аналогичны вектору информативных параметров, ответственных за аномальное состояние ГЦН, выделенных комплексом программ DINA-1 [6].




Рис.4. Показатели чувствительности

ВЫВОДЫ

Разработан программно-алгоритмический комплекс, обеспечивающий диагностику состояния ГЦН. Программа позволяет распознавать аномалию в поведении главных циркуляционных насосов на ранней стадии развития, что дает возможность своевременно принять меры для устранения причин нестабильной работы насоса и предотвратить аварию.

В основе программы лежит нейронная сеть "backpropagation", обучение которой производилось по методу градиентного спуска. Обучение требует не менее 10000 циклов.

Обучение и проверка работы программы производились на данных Калининской и Нововоронежской АЭС. Сеть распознает аномальную ситуацию на обеих станциях, связанную с блоком уплотнения ГЦН, с вероятностью приблизительно 96%. В процессе обучения проведен анализ чувствительности сети к входным параметрам, что позволило выделить среди них наиболее значимые при развитии рассмотренной ситуации. Наибольший вес при обучении имели следующие параметры: давление за первой ступенью уплотнения и давление запирающей воды на выходе из ГЦН.

Литература

1. Копьев Ю.В. Экспресс анализ работы АЭС России за первое полугодие 2000 г. Концерн «РосЭнергоАтом».
2. Антонов Б.В. Итоги эксплуатации АЭС России в 1995 г. // Ядерная энергетика. – 1996. - №3. - С. 4-10.
3. Лескин С.Т., Зарюгин Д.Г. Алгоритм диагностирования состояния ГЦН по данным оперативного технологического контроля // Безопасность АЭС и подготовка кадров. - Обнинск, 1999.
4. Лескин С.Т., Зарюгин Д.Г. Разработка алгоритмов распознавания состояния оборудования АЭС по анализу данных оперативного технологического контроля // Научные исследования в области ядерной энергетики в технических вузах России. - М.: МЭИ, 1999.
5. Adeli H., Yeh C. Neural Network learning in Engineering Design // INNC, vol.1, Paris, 1990.
6. Лескин С.Т., Зарюгин Д.Г. Комплекс программ DINA-I для диагностирования главных циркуляционных насосов ВВЭР по данным оперативного технологического контроля // Известия вузов. Ядерная энергетика. - 2001. - №1. - С. 3-12.
7. Petrowski Alain, Dreyfus Gerard Claude Girault, Performance Analysis of a Pipelined Backpropagation Parallel Algorithm // IEEE Transactions on Neural Networks. – 1993. - Vol.4. - №6. - P. 970-981.
8. Горбань А.Н. Обучение нейронных сетей. - М.: изд. СССР-США СП «ParaGraph», 1990. - 160 с. (English Translation: AMSE Transaction, Scientific Siberian, A, 1993, Vol. 6. Neurocomputing).

Поступила в редакцию 18.04.2001

ABSTRACTS OF THE PAPERS

УДК 519.714.1:621.039.58

Non-asymptotic Model for System Reliability with Built-in Control \A.V. Antonov, A.V. Dagayev, V.A. Chepurko; Editorial board of Journal "Izvestia visshikh uchebnikh zavedeniy, Yadernaya energetika" (Communications of Higher Schools. Nuclear Power Engineering) - Obninsk, 2001. - 7 pages, 5 illustrations, 1 table.- References, 6 titles.

The paper considers method of calculation for system reliability with a build-in control of trouble-free operation subjected to recovery after failure. The model is developed permitting to calculate non-asymptotic and asymptotic availability coefficient. The comparison of reliability indexes is performed, and the literature is briefly summarized for given subject.

УДК 519.217:621.039.58

The Development of Optimization Criterion for NPP Unit Life Time \O.M. Gulina, A.A. Zgiganshin, V.A. Chepurko; Editorial board of Journal "Izvestia visshikh uchebnikh zavedeniy, Yadernaya energetika" (Communications of Higher Schools. Nuclear Power Engineering) - Obninsk, 2001. - 5 pages, 2 illustrations.- References, 7 titles.

There is developed the optimization criterion for NPP unit lifetime depending on both safety demands and economical cost. The new results for the operation cost due to equipment unreliability are obtained by using of Markovian model. To make decision about life time extension the method of zero level crossing is suggested for different kinds of information about criterion parameters.

УДК 621.039+621.039.586

Application of Neural Network for Main Circulation Pumps Diagnostic \S.T. Leskin, V.V. Valuy, D.G. Zarugin Editorial board of Journal "Izvestia visshikh uchebnikh zavedeniy, Yadernaya energetika" (Communications of Higher Schools. Nuclear Power Engineering) - Obninsk, 2001. - 7 pages, 4 illustrations, 1 table.- References, 8 titles.

The application of Neural Network for VVER 1000 Main Circulation Pumps Diagnostic is discussed. On The base of selected Model and principles of education the Neural Network is developed. The results of application of the Neural Network, previously educated on the fifth block NV NPP and the first block Kalinin NPP data, are presented. The sensitivity analyze of the Neural Network for the entering data was carried out to outline the most influencing on the education process of MCP anomalies conditions recognizing.

УДК 621.039.526

«Cold» Nuclear Reactor with Direct Nuclear - Electric Energy Conversion Based on Secondary Electrons within the Frame of Nuclear Material Non – Proliferation \V.B. Anufrienko, G.N. Kazantsev, V.P. Kovalev, A.G. Matkov, G.M. Pshakin, M.Ya. Khmelevsky; Editorial board of Journal "Izvestia visshikh uchebnikh zavedeniy, Yadernaya energetika" (Communications of Higher Schools. Nuclear Power Engineering) - Obninsk, 2001. - 8 pages, 4 illustrations, 2 table.- References, 8 titles.

One of the problems in developing nuclear power at the current stage consists in non - proliferation of nuclear materials (NM) and technologies which can be used for constructing explosive devices.

So the attempt to make the equipment and power units requirements more stringent is justified. These requirements could provide a higher level of resistance to proliferation and unauthorized use of NMs at all the stages of nuclear fuel cycle. In this respect additional possibilities are revealed when developing new ways of direct conversion of nuclear power into the electric one.

This paper considers the concept of a nuclear reactor with direct (avoiding a thermal stage) conversion of nuclear energy into electric energy by means of accumulation of secondary electrons (SE) generated in the substance by fission fragments. The conversion technique is based on the use of electrogenerating elements (EGEs) which simultaneously are reactor fuel cores in the form